Применение сети Хопфилда для идентификации мошеннических банковских транзакций

Введение

В мире регулярно происходят мошеннические транзакции, и хотя основным методом их идентификации являются классификаторы (такие как решающие деревья, random forest и их модификации), они часто неэффективны при работе с зашумленными или неполными данными, что требует применения иных нейросетевых архитектур.

В этой работе я рассмотрел альтернативный способ выявления мошеннических транзакций с применением сети Хопфилда. Преимуществами такого подхода могут являться простота обучения и возможность оперативного дообучения при появлении новых видов мошенничества, а также совместимость с архитектурой альтернативных (оптических) компьютеров.

Цель и задачи

Цель исследования: разработка сети Хопфилда для идентификации мошеннических транзакций.
Задачи:

- Предобработка данных
- Выбор паттернов среди легитимных и мошеннических транзакций
- Обучение сети Хопфилда
- Подбор гиперпараметров (длина бинарного вектора, количество паттернов, количество итераций)
- Тестирование и сравнение метрик сети Хопфилда и решающего дерева

Выполнение

Анализ и предобработка данных

Для решения задачи был выбран датасет на Kaggle: https://www.kaggle.com/datasets/computingvictor/transactions-fraud-datasets/data

В нем отдельно содержались: информация о транзакциях, о пользователях, о картах и метки (мошенническая/легитимная транзакция)

Все датасеты были объединены в один. Были изменены либо удалены некоторые признаки, так как при просмотре данных вручную стало ясно, что не все данные могут нести полезную информацию. Так, например, признак date был разбит на отдельные year, month и day, а expire был заменен на days_to_expire. После фич-инжинеринга на получившемся датасете было обучено решающее дерево и с помощью него, были выявлены наиболее значимые признаки (рис. 1).

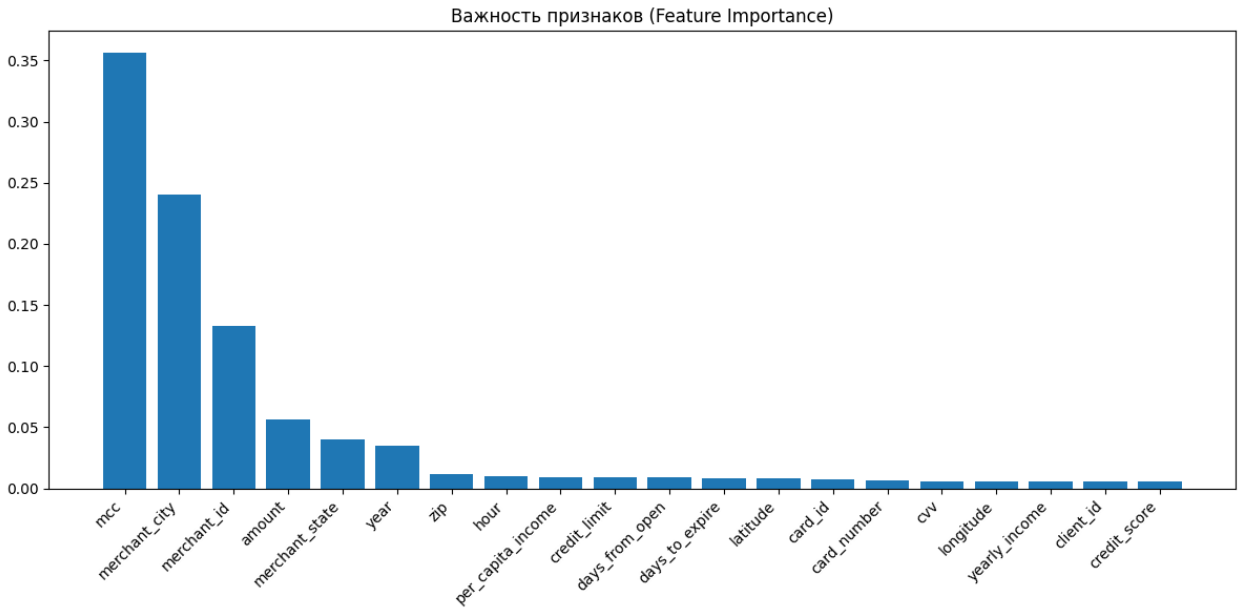

Рис. 1. Значимость признаков (на основе результатов обучения решающего дерева)

Для дальнейшей работы с данными были оставлены лишь 15 наиболее значимых признаков.

Схема работы с данными

Обучение

Рис. 2. Схема обучения

На этапе обучения (рис. 2) исходные данные проходят через цепочку преобразований, целью которых является формирование эталонных паттернов для сети Хопфилда:

1. **Предобработка и фич-инжиниринг:** Исходный датасет очищается, производится отбор наиболее значимых признаков (на основе анализа важности признаков, полученных с помощью решающего дерева).

2. **Энкодинг:** Подготовленные признаки транзакций преобразуются в бинарные вектора фиксированной длины, которые могут быть обработаны сетью Хопфилда.

3. **Кластеризация (k-Means):** Так как количество транзакций в датасете огромно, а сеть Хопфилда имеет ограничения на количество запоминаемых паттернов, необходимо выбрать репрезентативную выборку эталонов. Для этого применяется алгоритм k-Means, который группирует все бинарные вектора на два класса: легитимные и мошеннические транзакции. Центроиды полученных кластеров (либо близкие к ним вектора) используются в качестве эталонных паттернов.

4. **Обучение сети Хопфилда:** Отобранные паттерны подаются в сеть, где по правилу Хебба вычисляется матрица весовых коэффициентов. Эта матрица фиксирует энергетический ландшафт сети, где каждый паттерн становится локальным минимумом (аттрактором).

Тестирование

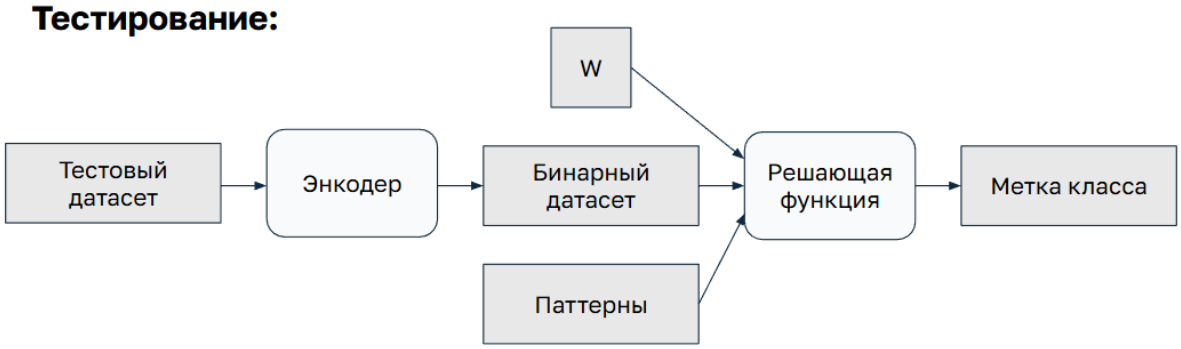

Рис. 3. Схема тестирования

На этапе тестирования (рис. 3) новый, неразмеченный набор данных проходит схожую обработку, но уже без участия эталонов:

1. **Предобработка и энкодинг:** Тестовые данные проходят те же этапы предобработки и преобразуются в бинарный вектор с помощью того же энкодера.
2. **Подача в обученную сеть:** Полученный бинарный вектор подается на вход уже обученной сети Хопфилда.
3. **Итеративная релаксация (Сходимость):** Сеть итеративно обновляет состояние своих нейронов (асинхронно или синхронно) до тех пор, пока состояние не перестанет изменяться. Это означает, что вектор "упал" в один из энергетических минимумов, то есть сошелся к ближайшему эталонному паттерну.
4. **Классификация:** Если финальное состояние сети совпадает с паттерном, соответствующим мошеннической транзакции (либо если процесс сходимости занял значительное количество итераций, согласно альтернативной гипотезе), транзакция помечается как подозрительная.

Энкодинг

Для использования сети Хопфилда в качестве классификатора данные необходимо преобразовать в бинарные вектора фиксированной длины. Был разработан энкодер, преобразующий 15 отобранных признаков в бинарную квадратную матрицу, которая затем интерпретируется как состояние нейронной сети. Процесс энкодинга включал

нормализацию числовых признаков и их последующую бинаризацию, а также преобразование категориальных переменных.

Выбор паттернов и обучение сети

Ключевым этапом стал выбор эталонных паттернов (аттракторов) для обучения сети. Так как сеть Хопфилда относится к моделям ассоциативной памяти, ей необходимо предъявить эталонные образцы легитимных и мошеннических транзакций. Для этого из всего множества бинарных векторов, полученных на этапе энкодинга, необходимо было выбрать репрезентативные паттерны. В данной работе для кластеризации данных и последующего отбора паттернов был применен алгоритм k-Means, что позволило выделить наиболее характерные векторы как для класса нормы, так и для класса аномалий. В итоговой реализации были выбраны 4 мошеннических и 6 легитимных паттернов. Общее их количество не превышает 10% от числа нейронов, значит такое количество теоретически допустимо. Обучение сети происходило по правилу Хебба с нормализацией и обнулением диагональных элементов весовой матрицы:

$W = \frac{1}{N}\sum_{i=1}^{P}\left(\mathbf{x}_i\mathbf{x}_i^T - I\right)$, где *N* — количество нейронов, а *P* — количество паттернов.

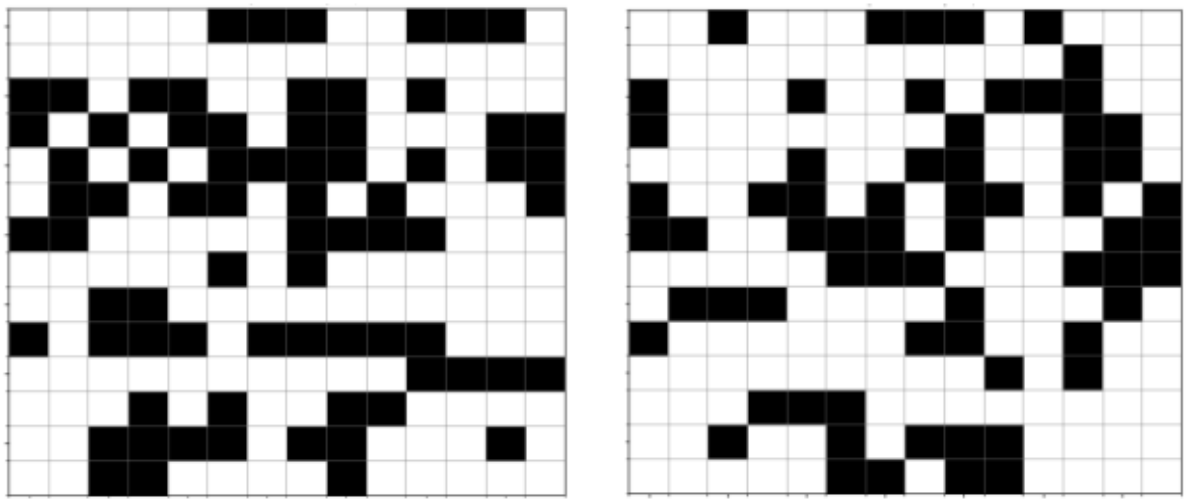

Рис. 4. Примеры паттернов, преобразованных к матричной форме. Слева мошеннический, справа легитимный

Тестирование и анализ результатов

Тестирование обученной сети Хопфилда проводилось путем подачи на вход тестовых бинарных векторов и итеративного обновления состояний нейронов до сходимости к одному из эталонных паттернов. Классификация транзакции определялась тем, к какому эталону (легитимному или мошенническому) сошелся вектор. В качестве базы для сравнения использовалось решающее дерево, обученное на том же наборе данных.

Результаты первичного тестирования показали, что реализованная сеть Хопфилда значительно уступает классическому алгоритму:

* **Решающее дерево** продемонстрировало ожидаемо высокие результаты на структурированных данных: Accuracy ≈ 99%, F1-score ≈ 0.7.
* **Сеть Хопфилда** показала низкую эффективность в текущей конфигурации: Accuracy ≈ 67%, F1-score ≈ 0.1.

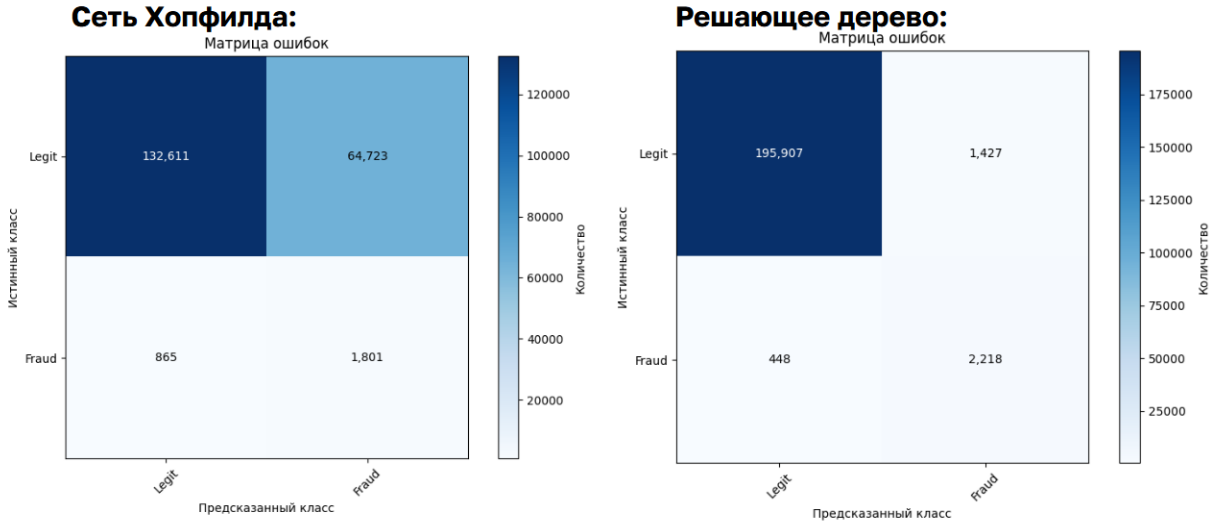

Accuracy ≈ 67%
f1 ≈ 0.1

Accuracy ≈ 99%
f1 ≈ 0.7

Низкое значение F1-меры свидетельствует о большом количестве ложноположительных срабатываний и проблемах с идентификацией именно мошеннических операций, что является критичным для данной задачи.

Заключение и дальнейшие планы

В ходе выполнения работы была разработана и обучена сеть Хопфилда для выявления мошеннических банковских транзакций. На данном этапе она действительно уступает классическому методу (решающему дереву), что подтверждает сложность адаптации моделей ассоциативной памяти под задачи классификации табличных данных.

Однако полученные результаты не являются окончательными. Низкая точность обусловлена сложностью прямого переноса задачи классификации на архитектуру, изначально предназначенную для восстановления образов. Дальнейшее исследование будет направлено на улучшение работы модели за счет изменения подхода к эмбеддингу данных и модификации принципа работы решающей функции. В частности, планируется:

1. Изменить эмбеддинг данных и размерность бинарных матриц для более полного сохранения информации о признаках.
2. Изменить логику классификации: подавать на вход сети только легитимные паттерны. В таком случае на этапе тестирования скорость сходимости вектора к эталону будет выступать в роли критерия — быстрая сходимость будет соответствовать легитимной транзакции, а медленная или ее отсутствие — мошеннической.

Планируется, что применение этих идей позволит повысить точность и F1-меру сети Хопфилда до значений, близких к показателям решающих деревьев.